

UF 5: Análisis de Datos

1. El ciclo de vida de los datos

El ciclo de vida de los datos describe todas las etapas que sigue la información desde su generación hasta su eliminación. Comprender este ciclo es crucial para gestionarlo de manera eficiente y para que los resultados de su análisis sean fiables. A continuación, se explican cada una de las fases y los aspectos más relevantes en entornos productivos.

1.1. Recogida de datos (data collection)

Fuentes de datos

Bases de datos internas: Pueden ser sistemas CRM (Customer Relationship Management), ERP (Enterprise Resource Planning), u otras aplicaciones de negocio que recopilan datos estructurados.

Archivos log: Registros de actividad de aplicaciones, servidores o dispositivos que recogen información de eventos (por ejemplo, logs de acceso, errores, etc.).

Dispositivos IoT: Sensores y dispositivos conectados que generan datos en tiempo real (temperatura, presión, ubicación, etc.).

Aplicaciones móviles: Información generada por usuarios al interactuar con apps (ubicación, acciones dentro de la app, preferencias).

Sistemas de venta: Información de facturación, stock, ventas en línea o en tienda física.

Redes sociales: Datos de interacciones, publicaciones, reacciones de los usuarios, etc.

Calidad de los datos

Consistencia y precisión: Los datos deben ser coherentes entre distintas fuentes (mismos formatos, mismos rangos de valores, etc.).

Relevancia: Solo se deben recolectar datos que aporten valor. Recopilar datos irrelevantes o redundantes dificulta el análisis y aumenta costes.

Garbage in, garbage out: Si la información de entrada está corrupta o es poco fiable, las conclusiones derivadas serán erróneas o poco útiles.

Formatos de datos

Datos estructurados: Se organizan en tablas (SQL). Ejemplo: un registro con columnas de nombre, dirección, fecha.

Datos semiestructurados: Tienen cierta organización pero no tan rígida (JSON, XML).

Datos no estructurados: Texto libre, imágenes, audio, vídeo. Resultan más complejos de analizar, pero suelen contener información muy valiosa.

1.2. Almacenamiento de datos (data storage)

Sistemas de almacenamiento tradicional

Bases de datos relacionales (SQL): Se basan en un modelo de tablas relacionadas (MySQL, PostgreSQL, Oracle).

Servidores on-premise: Infraestructura física en las instalaciones de la empresa. Se requiere inversión en hardware, mantenimiento y soporte.

Sistemas de almacenamiento distribuido y en la nube

Bases NoSQL (MongoDB, Cassandra, etc.): Ideales para datos con gran variedad de formatos y grandes volúmenes, ya que permiten un escalado más ágil.

Almacenamiento en cloud (Amazon S3, Google Cloud Storage, Azure Blob Storage): Ofrece flexibilidad, pago por uso y alta disponibilidad. Resulta clave para empresas con picos de demanda.

Seguridad y protección de datos

Control de accesos: Definir quién puede ver, modificar o eliminar información.

Copias de seguridad y planes de recuperación de desastres: Garantizan la continuidad del negocio ante caídas de sistemas o pérdidas de información.

Cifrado en reposo y en tránsito: Protege la confidencialidad de los datos tanto cuando están almacenados como cuando viajan por la red.

1.3. Análisis de datos (data analysis)

Tipos de análisis

Descriptivo: Responde a la pregunta “¿qué ha ocurrido?”. Utiliza informes, resúmenes y estadísticas para describir el pasado.

Predictivo: Busca predecir comportamientos o resultados futuros con base en datos históricos y algoritmos estadísticos o de machine learning.

Prescriptivo: Propone recomendaciones concretas sobre qué acciones tomar tras el análisis (ej. optimización de recursos, ofertas personalizadas).

Herramientas y metodologías

Lenguajes de programación: Python y R destacan por sus librerías (pandas, numpy, ggplot2, etc.) orientadas al análisis y la visualización de datos.

Herramientas de visualización: Power BI, Tableau o Qlik facilitan la creación de paneles interactivos y gráficos que ayudan a interpretar la información.

Interpretación de resultados

Transformar datos en conocimiento: Un buen análisis no se limita a crear tablas y gráficos, sino que extrae conclusiones accionables para la organización.

Identificación de patrones e insights: Detectar tendencias, correlaciones y anomalías para anticiparse a problemas o descubrir oportunidades de negocio.

1.4. Retención y eliminación de datos (data retention & disposal)

Ciclo de retención

Políticas de retención de datos: Se basan en normativas legales (RGPD en Europa, LOPD en España) o necesidades internas (por ejemplo, conservar facturas durante X años).

Compliance: Asegurar que la empresa cumple los requisitos legales, evitando sanciones y problemas reputacionales.

Eliminación segura

Borrado lógico vs. borrado físico:

El borrado lógico marca los datos como “eliminados” pero pueden recuperarse con herramientas especializadas.

El borrado físico o seguro sobrescribe el medio de almacenamiento, dificultando la recuperación.

Riesgos de retener datos innecesarios:

Costes adicionales de almacenamiento.

Aumento de la superficie de ataque y posible violación de la privacidad.

1.5. Gestión eficiente de datos en entornos productivos

Automatización de procesos

ETL (Extract, Transform, Load): Conjuntos de herramientas y scripts que extraen datos de múltiples fuentes, los transforman para un formato común y los cargan en un sistema de almacenamiento o análisis.

Integración continua: Permite mantener flujos de datos actualizados en tiempo real o casi real, evitando la desincronización de la información.

Gobernanza de datos (data governance)

Roles y responsabilidades: Definir quién es responsable de la calidad de los datos, de sus políticas de acceso y de la seguridad.

Estándares de calidad de datos y políticas de acceso: Garantizan que la organización utilice la información de forma coherente y proteja la privacidad de los usuarios.

Optimización de recursos

Reducción de duplicidades: Evita que la empresa mantenga copias redundantes de la misma información, lo que incrementa costes y complica el análisis.

Escalabilidad y sistemas distribuidos: Permite manejar grandes volúmenes de datos y crecer según la demanda, sin caer en cuellos de botella.

2. El Big Data

En este bloque se profundiza en el concepto de Big Data, sus características distintivas y su importancia para la toma de decisiones en la industria. El tratamiento de grandes volúmenes de información permite a las empresas optimizar procesos, mejorar su relación con los clientes y descubrir nuevas oportunidades de negocio.

2.1. Definición y características del Big Data

Concepto de Big Data

Se entiende como el manejo de conjuntos de datos demasiado grandes o complejos para ser tratados con herramientas de procesamiento convencionales.

Sus principales rasgos son el **volumen** (gran cantidad de datos), la **velocidad** (ritmo acelerado de generación) y la **variedad** (múltiples formatos y fuentes).

Las 5 V del Big Data

Volumen

Hace referencia a la cantidad masiva de datos que se generan a diario (por ejemplo, registros de transacciones bancarias, logs de aplicaciones, datos de sensores).

Implica la necesidad de infraestructuras escalables y distribuidas para almacenar y procesar la información.

Velocidad

La exigencia de procesar datos en tiempo real o casi real (streaming) para tomar decisiones de manera ágil.

Sectores como el financiero o la industria 4.0 requieren respuestas inmediatas.

Variedad

Incluye datos estructurados (tablas SQL), semiestructurados (JSON, XML) y no estructurados (texto, audio, vídeo, imágenes).

Esta diversidad obliga a utilizar tecnologías adaptadas a cada tipo de dato.

Veracidad

Se refiere a la calidad y fiabilidad de la información.

Datos inexactos o incompletos pueden derivar en conclusiones erróneas; por ello es vital garantizar su validez.

Valor

El potencial de los datos para generar beneficios tangibles (reducción de costes, incremento de ventas, mayor satisfacción del cliente).

La información debe ser transformada en conocimiento y acciones concretas para ser realmente útil.

Diferencias con los datos convencionales

El volumen y la complejidad de Big Data demandan nuevos métodos de almacenamiento y procesamiento, como **Hadoop** o **Spark**, en lugar de depender exclusivamente de servidores tradicionales.

El escalado horizontal (sumar más nodos) resulta más habitual que el escalado vertical (aumentar la potencia de un solo servidor).

2.2. Aplicaciones del Big Data en la mejora de la productividad empresarial

Análisis de comportamiento del cliente

Segmentación de usuarios, marketing personalizado y sistemas de recomendación (por ejemplo, mostrar productos afines a gustos previos).

Permite predecir tendencias y adaptar la oferta de la empresa en función de la demanda real.

Optimización de procesos internos

Planificación de la producción: Ajuste de recursos según predicciones de demanda.

Análisis de la cadena de suministro: Detección de cuellos de botella y mejora de la logística.

Mantenimiento predictivo: Uso de datos de sensores para anticipar fallos de maquinaria, evitando paradas costosas y alargando la vida útil del equipo.

Innovación y desarrollo de productos

Al analizar grandes conjuntos de datos, surgen insights para crear nuevas líneas de negocio.

Ejemplo: monitorear en redes sociales las opiniones de usuarios para adaptar y mejorar productos existentes.

Casos de éxito en la industria

Amazon: Aprovecha los datos de compra e historial de navegación para recomendar productos y optimizar su logística.

Netflix: Emplea algoritmos de recomendaciones personalizadas basadas en el comportamiento de visionado y valoraciones de los usuarios.

2.3. Desafíos del Big Data

Escalabilidad y complejidad

Gestionar grandes infraestructuras distribuidas conlleva retos técnicos: coordinación de nodos, redundancia de datos, equilibrio de carga.

Es necesario personal con habilidades especializadas (data engineers, data scientists).

Privacidad y cumplimiento legal

El volumen de datos personales manejados exige cumplir normativas como el **RGPD** (Reglamento General de Protección de Datos) en la Unión Europea.

Importancia de la protección de datos y de salvaguardar la confidencialidad de la información sensible.

Retorno de la inversión (ROI)

Implantar soluciones de Big Data (infraestructura, personal, software) puede suponer costes elevados.

Es clave alinear el uso de los datos con objetivos claros de negocio y medir regularmente su impacto para justificar la inversión.

3. Machine Learning

En este bloque se presenta el **aprendizaje automático (Machine Learning)**, una rama de la inteligencia artificial que tiene un gran impacto en el análisis **de datos** y en la optimización de procesos en entornos productivos. A continuación, se describen sus fundamentos y su aplicación práctica.

3.1. Concepto de Aprendizaje Automático (Machine Learning)

Definición

El Machine Learning se centra en el desarrollo de algoritmos que permiten a las máquinas **aprender de la experiencia** (datos) sin haber sido programadas explícitamente para una tarea específica.

Con esto, el sistema mejora su rendimiento a medida que procesa más información.

Tipos de Aprendizaje

Aprendizaje supervisado: El modelo se entrena con datos de entrada (features) y sus etiquetas o valores objetivo (labels).

Clasificación: Asignar una categoría (spam/no spam, defectuoso/no defectuoso).

Regresión: Predecir un valor continuo (ventas, temperatura, demanda futura).

Aprendizaje no supervisado: El modelo no tiene etiquetas, sino que descubre patrones en los datos por sí mismo.

Clustering: Agrupar los datos en función de similitudes (segmentación de clientes).

Reducción de dimensionalidad: Simplificar la cantidad de variables para visualizar o trabajar con los datos de forma más eficiente.

Aprendizaje por refuerzo: El sistema aprende a través de interacciones con un entorno, recibiendo **recompensas** o **castigos** según sus acciones. Es muy utilizado en robótica y en optimización de procesos.

Ciclo de vida de un modelo de ML

Recolección de datos: Reunir conjuntos de datos relevantes para el problema a resolver.

Limpieza y preprocesado: Eliminar o corregir outliers, valores faltantes, datos inconsistentes.

División en conjuntos de entrenamiento y validación: Generalmente se reservan datos para testear el modelo y evitar sobreajuste.

Entrenamiento: Ajuste de parámetros del modelo a partir de los datos de entrenamiento.

Evaluación: Medición del rendimiento con métricas como la precisión, el error cuadrático medio, el F1-score, etc.

Despliegue y mantenimiento: Puesta en producción del modelo y actualización periódica para que siga siendo relevante.

3.2. Relación con el Análisis de Datos

Modelos predictivos

El ML enriquece el análisis de datos al **predecir resultados futuros** (por ejemplo, ventas próximas, fallos en maquinaria, comportamiento de clientes).

Los análisis predictivos basados en ML permiten a las empresas tomar decisiones proactivas, reducir riesgos y optimizar procesos.

Procesamiento de grandes volúmenes de datos (Big Data + ML)

El Machine Learning se potencia con **grandes conjuntos de datos** que mejoran la precisión de los algoritmos.

Herramientas como **Spark MLlib** permiten entrenar modelos de manera distribuida, aprovechando la escalabilidad en entornos Big Data.

Importancia de la calidad de datos

El modelo depende de la fiabilidad de los datos de entrenamiento: **“garbage in, garbage out”**.

Un conjunto de datos con inconsistencias o información irrelevante produce modelos menos precisos.

3.3. Ejemplos Prácticos de Machine Learning en el Sector Productivo

Mantenimiento predictivo

Análisis de datos de sensores (vibraciones, temperatura, uso) para anticipar fallos antes de que se produzcan.

Reduce costes de reparación y tiempos de inactividad no planificados.

Optimización de la logística

Algoritmos de ruta o planificación de flotas basados en técnicas de ML.

Previsión de demanda para ajustar inventario y evitar sobrecostes o roturas de stock.

Control de calidad en producción

Visión por computador que detecta defectos de manera automática y en tiempo real en líneas de ensamblaje.

Aumenta la fiabilidad y reduce el tiempo invertido en revisiones manuales.

Personalización de productos y servicios

Segmentación de clientes y recomendaciones basadas en algoritmos de ML (collaborative filtering, deep learning).

Mejora la experiencia del cliente y potencia las ventas cruzadas.

3.4. Herramientas y Plataformas para Machine Learning

Entornos de desarrollo

Python: Con librerías populares como **scikit-learn**, **TensorFlow**, **PyTorch**, **pandas**, etc.

R: Orientado al análisis estadístico y visualización (caret, tidyverse).

MATLAB: Muy usado en entornos académicos e industriales para prototipado rápido.

Servicios en la nube

AWS Sagemaker: Plataforma para entrenar y desplegar modelos en Amazon Web Services.

Azure Machine Learning: Ofrece pipelines automatizados de ML y herramientas de gestión de experimentos.

Google Cloud AI Platform: Integra TensorFlow con la infraestructura de Google Cloud.

Retos y buenas prácticas

Interpretabilidad de los modelos (Explainable AI): Entender cómo el algoritmo llega a una conclusión, vital en entornos críticos o regulados.

Mantenimiento y actualización de modelos: La realidad de los datos cambia con el tiempo (drift), por lo que el modelo debe recalibrarse y reevaluarse periódicamente.